

Hadamard Rotation 与 Lloyd-Max Quantization

计算不变性


$$H^T H = I, \quad y = xW^T = (xH)(WH)^T$$

$$QK^T = (QH)(KH)^T$$

- Hadamard rotation 是正交换基；不量化时不改变 Linear / Attention score。
- Rotation 负责平滑 outlier，使 block / head 内 scale 更稳定。
- Rotation 后激活值分布更趋于 Gaussian 分布，是适配 Lloyd-Max 量化的先决条件。


Lloyd-Max codebook

$$\hat{x} = s \cdot c_{i^*}, \quad i^* = \arg \min_i |x/s - c_i|$$




- Lloyd-Max 在 RMS 标准化后的近似 Gaussian 分布上最小化 MSE。
- Lloyd-Max 量化结果是 fixed centroid codebook，通过索引 dequant。
- 后续硬件协同设计可考虑 LUT-based 计算单元。


当前模型量化计算流



Attention path: post-RoPE H64 + KV HLM




FFN path: shared gate/up quant + second down-proj activation quant



主要关注: Rot-LM W4A4 + HLM K4V4; Attention 与 FFN 分别替换 `self_attn` 和 `mlp`, $Q_A(\cdot)$ 和 $Q_W(\cdot)$ 分别表示 activation / weight quantizer。


Full-model PPL 实验结果



- **Best 4-bit:**
Full Rot-LM W4A4 + HLM K4V4, PPL = **9.23**.
- **Baselines:**
MXFP4 = 10.26, Direct Absmax = 11.12, Rot-MXFP4 = 10.15.
- **Rotation backend:**
Hadamard / Rand-Hadamard / Rand-Ortho 分别为 9.23 / 9.37 / 9.80。
- **Block size:**
W4A4 下 32/64/128 接近, block size 取 64 结果最优。


后续方向: FWHT + LUT-based Codebook Compute

Rotation path: FWHT butterfly



- Hadamard rotation 可由 FWHT 实现, 核心为 add/sub 与 routing.
- 支持 H32 / H64 / H128 block-local rotation, 避免 dense matrix multiply.

Linear path: LUT-based Lloyd-Max MAC



- Lloyd-Max 存储 codebook index, 计算需要 centroid lookup.
- 设计 Codebook-aware RQ-GEMM kernel 或 Fused FWHT + RQ-GEMM kernel.
- 对比: GPU 上的 INT4 GEMM kernel 和 FPGA 上实现的 Naive dequantize-then-MAC FPGA kernel.